

Plan phân tích hành vi LLM trong AI Race

Trạng thái: bản nháp đề xuất, chưa được phê duyệt. Chưa phải preregistration.

Quan hệ với tài liệu khác: [PROJECT.md](#) là protocol nghiên cứu đang có hiệu lực; tài liệu này đề xuất mở rộng nó theo ba trục. Mọi mâu thuẫn giữa hai file phải được giải quyết về phía `PROJECT.md` cho tới khi plan này được duyệt và merge vào đó.

Paper nguồn: Fernández Domingos & Han (2026), *Falling Behind Drives Unsafe Development in an Idealised AI Race Experiment* ([arXiv-2607.26034v1/paper.tex](#)).

§ 0. Bốn phát hiện từ code quyết định toàn bộ thiết kế

Plan này được viết sau khi đọc engine, runner, recorder, analyser (~3.2k dòng), classifier và Kaggle manifest. Bốn quan sát dưới đây thay đổi cách thiết kế phải viết.

(1) Persona đã plumb sẵn end-to-end, và KHÔNG đung vào prompt hash

- [ai_race/prompts/ai_race_en.txt](#) dòng 2 có sẵn placeholder `{persona_block}`.
- [ai_race/engine/prompt.py](#) dòng 71–74 render nó thành `"\nAdditional role instruction:\n<text>\n"`, và bỏ trống khi persona rỗng.
- [ai_race/runner/run_experiment.py](#) dòng 37–44 đọc `personas[language][seat]` từ agents config.

Nghĩa là **persona là một trục agents-config, không phải một prompt version mới**.

File template không đổi một byte, hash `6180d4f6...` giữ nguyên, invariant trong `CLAUDE.md` không bị vi phạm. Đây là ý đồ thiết kế có sẵn:

[companies_default.json](#) cố ý set

`personas: {"en": [ "", "" ]}` và mô tả mình là "no safety or risk persona is injected".

Hệ quả cho plan: không cần bump `promptVersion` cho các arm persona. Bump `promptVersion` thực ra là *phản tác dụng*, vì nó làm analyser hard-fail ở gate canonical-prompt (`analyze_ai_race.py:1411-1432`) và ép mọi output xuống nhãn "sensitivity audit".

(2) Nhưng persona hiện KHÔNG được ghi vào bất kỳ output nào → nguy cơ pooling ngầm

- `TurnRecord` trong `state.py` không có trường persona.
- `race_row` và `player_rows` trong `recorder.py` không có.
- `CONTEXT` của `analyser` (`analyze_ai_race.py:104-111`) chỉ gồm `model`, `max_private_risk`, `prompt_version`, `protocol_signature`, `run_phase`, `run_status`.
- Protocol signature (`analyze_ai_race.py:510-534`) gồm `prompt` / `model` / `decoding` / `seed_contract` / `mechanism` / `runtime` — **không có agents**.

Hệ quả: chạy persona và non-persona rồi phân tích chung thì analyser **không phát hiện được**, gộp im lặng, mọi bảng sai. Đây là bug chờ xảy ra và phải vá **trước** khi chạy run persona đầu tiên (§ 4.1).

Thông tin persona hiện chỉ tồn tại gián tiếp trong `game_id`, có dạng

```
{game}__{model}__{lang}__{agents}__rep{NNNN} (run_experiment.py:82-85).
```

Phục hồi

bằng cách parse string là fragile và không được dùng làm nguồn chính thức.

(3) CRN mạnh hơn dự kiến — và trải cả sang trực persona

`game_seed = base_seed + rep` (`run_experiment.py:79-81`), cố ý độc lập với tên treatment **và cũng độc lập với agents config**. Nên nếu mọi experiment config (baseline + tất cả persona cell) dùng chung `"seed": 260726`, thì **rep k trong mọi điều kiện có cùng horizon và cùng setback draw**.

Đây là matched-pairs design gần như miễn phí, mạnh hơn hẳn thí nghiệm người — nơi mỗi cặp participant chỉ chơi một treatment duy nhất.

- **Điều kiện bắt buộc:** không được đổi `seed` giữa các config.
- **Vấn đề cần vá:** `randomization_block_id = source_run::model::rep` (`analyze_ai_race.py:1510-1515`). Persona ở run directory khác → `source_run` khác → block bị tách sai. Xem § 4.3.

(4) ΔS không phải biến độc lập — nó là hiệu số hành vi Unsafe, đổi đơn vị

Đây là điểm phân tích sâu nhất trong toàn bộ plan. Trong cơ chế này:

$$\text{progress}_i(t) = 1 \cdot n_S + 1.5 \cdot n_U = (t - n_U) + 1.5 \cdot n_U = t + 0.5 \cdot n_U$$

$$\Rightarrow \Delta S(t) = \text{progress}_{\text{own}} - \text{progress}_{\text{opp}} = 0.5 \cdot (n_U^{\text{own}} - n_U^{\text{opp}})$$

ΔS đúng bằng một nửa hiệu số lần chọn Unsafe. Nó không phải "vị trí trong cuộc đua" theo nghĩa một biến độc lập — nó là "tôi đã liều hơn đối thủ bao nhiêu lần". Hệ quả đây chuyền:

- "Đang bị bỏ lại" $\Leftrightarrow$ "tôi đã an toàn hơn nó" $\Leftrightarrow$ "risk tích lũy của tôi thấp hơn nó" $\Leftrightarrow$ "payoff tích lũy của tôi thấp hơn nó". Bốn thứ này **hoàn toàn collinear** trong cơ chế gốc.
- Vậy hệ số $\Delta S_{\{t-1\}} = -0.296$ của paper người **không phân biệt được** giữa hai câu chuyện:
 - (a) **Áp lực vị trí** — "tôi dẫn trước nên không cần liều nữa";
 - (b) **Ngân sách rủi ro** — "tôi đã liều nhiều nên risk cao, giờ phải phanh".
- Paper kể câu chuyện (a) trong Discussion và đặt tên nó là *fear of falling behind*, nhưng dữ liệu không loại được (b).

Với LLM ta **có thể** tách được, vì ta điều khiển được cơ chế. Đây là đóng góp khoa học lớn nhất mà plan này có thể tạo ra, và nó nằm ở Arm D (§ 1.4).

§ 1. TRỰC 1 — Two-player non-persona (baseline)

1.1 Trạng thái: đã implement xong, chỉ cần freeze + scale

[baseline.json](#) +

[companies_default.json](#) đã đúng:

hai seat trung tính, persona rỗng, ba treatment 0.1/0.6/0.9, `runPhase: "pilot"`.

Không cần đổi code cho arm này. Chỉ cần tăng `repetitions` và freeze.

1.2 Vấn đề chí mạng #1 — Symmetry collapse

Prompt của seat 0 và seat 1 ở vòng 1 chỉ khác nhau ở `Company_1` / `Company_2`. Cùng model, temperature = 0 $\rightarrow$ **hai seat gần chắc chắn cho cùng một action**. Nếu model lại có xu hướng copy đối thủ (như người), race khoá vào mirror play vĩnh viễn:

$$\Delta S(t) = 0.5 \cdot (n_{U^{own}} - n_{U^{opp}}) = 0 \quad \text{với mọi } t$$

→ `race_state` luôn `"tied"` → **toàn bộ trục distance biến mất**;
`unsafe_by_race_state_turn.csv` chỉ còn một dòng; hệ số `progress_gap_before` không ước lượng được. Và `_fit_clustered_logit` sẽ raise `"clustered logit requires both Safe and Unsafe outcomes"` (`analyze_ai_race.py:2851`) nếu model quá đơn điệu.

Đây là kịch bản thất bại có xác suất cao nhất của cả nghiên cứu. Ba lớp phòng vệ, áp dụng đồng thời:

Lớp	Biện pháp	Ghi chú
L1	<code>temperature</code> $\in \{0.7, 1.0\}$, per-decision <code>sampling_seed</code> (đã có qua <code>game.sampling_seed()</code>)	Không dùng <code>temp = 0</code> cho arm hành vi. <code>Temp = 0</code> chỉ dùng cho một run <i>determinism check</i> riêng
L2	Arm B — đối thủ ngoại sinh (§ 1.3)	Bẻ đối xứng bằng thiết kế, không dựa vào noise
L3	Gate tiền nghiệm: pilot 10 rep; nếu tỉ lệ race có $\Delta S \equiv 0$ xuyên suốt > 40% → dừng, không scale , dồn nguồn lực sang Arm B/C	Ghi ngưỡng này vào preregistration trước khi chạy

Bổ sung — name-permutation check. Cho 50% số race hoán vị thứ tự tên thành `["Company_2", "Company_1"]` để đo seat effect thuần túy. Nếu ϕ_U của seat 0 $\neq$ seat 1 khi persona rỗng, đó là artifact vị trí và mọi kết luận persona sau này bắt buộc phải counterbalance.

1.3 Arm B — Đối thủ ngoại sinh (giải quyết Limitation 6 của paper)

Paper thừa nhận (§ Limitations, điểm 6): a_{-i}^{t-1} **không ngoại sinh**, nên hệ số +0.607 chỉ là tương quan có điều kiện, không phải nhân quả. Với LLM ta sửa được: **thay một seat bằng chiến lược lập trình cứng.**

- Seat 1 = một trong `AS`, `AU`, `CS`, `CAS`, `BEHIND_UNSAFE`, `RANDOM(p=0.5)`.

- Seat 0 = LLM.
- Chiến lược script không "nhìn" LLM theo nghĩa chiến lược, chỉ theo luật của nó → a_{-i}^{t-1} trở thành **ngoại sinh thật sự** → hệ số của nó là **hiệu ứng nhân quả**, không phải association.

Hai contrast quan trọng nhất:

- **AS vs AU**: cùng một LLM, đối thủ luôn-Safe vs luôn-Unsafe. Hiệu số ϕ_U là ước lượng nhân quả sạch của "reciprocal unsafe" — con số paper người không thể có.
- **RANDOM(0.5)**: arm tốt nhất về mặt thống kê, vì nó cho variance tối đa trên cả `opp_prev` lẫn ΔS mà vẫn ngoại sinh hoàn toàn.

Engine hiện chưa có backend "scripted player" — cần thêm, chi tiết ở § 4.2. Đây là **arm có giá trị khoa học cao nhất trên mỗi đồng chi phí** trong toàn bộ plan.

1.4 Arm D — Tách ΔS khỏi lịch sử Unsafe (exploratory, non-canonical)

Từ § 0(4): trong cơ chế gốc không thể tách. Cách rẻ nhất để tách: **handicap ngoại sinh** — cho seat 0 một `initialProgress` $\neq 0$, bốc theo rep từ $\{-1.5, -1, 0, +1, +1.5\}$.

Khi đó:

$$\Delta S(t) = \text{handicap} + 0.5 \cdot \Delta n_U$$

Hai nguồn biến thiên tách rời, và ta hồi quy đồng thời **cả ΔS lẫn Δn_U** — điều paper người không làm được:

- Nếu hệ số ΔS sống sót khi kiểm soát Δn_U → **câu chuyện vị trí đúng**, "fear of falling behind" là hiệu ứng thật.
- Nếu chỉ Δn_U sống sót → hiệu ứng thật là **ngân sách rủi ro**, và cách paper diễn giải cần được đặt lại.

Ràng buộc thủ tục: đây là mechanism change → cần trường `initialProgress` trong `GameConfig`, config game riêng, `run_phase` riêng, và **bắt buộc chạy analyser với `--allow-noncanonical-mechanism`**. Không bao giờ gộp vào primary analysis.

1.5 Cỡ mẫu

Baseline hiện repetitions: 3 → 3 rep × 3 treatment = 9 race/model = 18 trajectory.

Quá nhỏ, không dùng được cho bất kỳ inference nào.

Mục tiêu: **khớp cỡ mẫu phân tích của paper người** (2.888 quan sát, 172 cụm).

```
50 rep × 3 treatment = 150 race / model / điều kiện
                      = 300 trajectory
                      ≈ 2.700 player-round (sau khi bỏ vòng 1)
                      = 50 CRN block, mỗi block trải đủ 3 treatment ✓
                      (thoả gate ở analyze_ai_race.py:2856)
                      ≈ 2.700 lệnh gọi LLM / model / điều kiện
```

Quy trình hai bước, tránh đốt compute mù:

1. **Pilot 10 rep** → đo ICC trong CRN block, tỉ lệ degenerate, parse-failure rate, phân bố ΔS thực tế.
2. Tính lại N từ design effect quan sát được. **50 rep là sàn, không phải mục tiêu.**
Nếu ICC cao (LLM đồng nhất, mirror nhiều) có thể cần 100+ rep, hoặc kết luận rằng arm này không informative và dồn sang Arm B.

§ 2. TRỰC 2 — Persona

2.1 Nguyên tắc viết persona (quan trọng hơn nội dung persona)

Persona là **manipulation**, không phải **instruction**. Nếu viết "hãy chọn UNSAFE nhiều hơn" thì ta chỉ đo khả năng tuân lệnh, không đo hành vi chiến lược. Bốn ràng buộc bắt buộc, tất cả đều kiểm tra được bằng test tự động:

1. **Không nhắc chữ SAFE/UNSAFE**, không nhắc bất kỳ hành động cụ thể nào.
2. **Không nhắc lại payoff, risk number, hay luật chơi** — không được thêm thông tin chiến lược mà baseline không có. Đây chính là cảnh báo trong [references/papers/markdown/falling-behind-ai-race.md](https://github.com/anthropics/anthropic-coarse-grained-reasoning/blob/main/references/papers/markdown/falling-behind-ai-race.md) dòng 83: personas là *experimental factor* vì chúng có thể thêm thông tin chiến lược không có trong task gốc.
3. **Cân độ dài** — mọi persona nằm trong $\pm 10\%$ số token của nhau, và có một persona `neutral` cùng độ dài làm placebo, để tách "hiệu ứng persona" khỏi "hiệu ứng có thêm một đoạn text".

4. Hash và ghi lại — `persona_sha256` vào run manifest.

Test cho (1) và (3) đặt ở `ai_race/tests/test_personas.py`.

2.2 Lưới điều kiện

Hai họ persona: risk preference (trực *dispositional*) và social orientation (trực *chiến lược*).

Họ R — Risk preference (đối xứng, cả hai seat cùng persona):

Cell	Seat 0	Seat 1	Vai trò
R0	neutral placebo	neutral placebo	Placebo cùng độ dài
R-	risk-averse	risk-averse	
R+	risk-seeking	risk-seeking	

Họ S — Social orientation (cả đối xứng lẫn bất đối xứng):

Cell	Seat 0	Seat 1	Vai trò
S_CC	cooperative	cooperative	Cả hai hợp tác
S_AA	adversarial	adversarial	Cả hai đối kháng
S_AC	adversarial	cooperative	Bất đối xứng — cell quan trọng nhất
S_CA	cooperative	adversarial	Counterbalance seat cho S_AC

S_AC / S_CA là cell có giá trị nhất: nó đo **hợp tác có sống sót được trước đối kháng không**, và nó bẻ đối xứng theo thiết kế nên né được vấn đề § 1.2. Bắt buộc có cả hai chiều, nếu không hiệu ứng persona lẫn với hiệu ứng seat.

Cộng baseline `none` → **8 điều kiện persona × 3 treatment risk = 24 cell**.

Nếu ngân sách chặt, cắt theo thứ tự ưu tiên: **giảm số model trước, không giảm số cell**. Trong trường hợp buộc phải cắt cell, thứ tự bỏ là R0 (mất placebo — chấp nhận được nếu báo cáo rõ), rồi S_CC. Không bao giờ bỏ S_CA (mất counterbalance) hay bỏ cả họ R (mất phần trả lời trực tiếp H2 của paper).

2.3 Vì sao trực risk-preference là đóng góp thật, không phải làm cho đủ

Paper người **đo** risk preference bằng Eckel–Grossman và ra null (hệ số -0.012 đến -0.027 , $p > 0.1$ ở mọi đặc tả). Nhưng đo lường có sai số, task elicitation có thể không valid, và null của một biến *đo được* là bằng chứng yếu.

Với LLM ta **áp đặt** risk preference thay vì đo. Ba kết cục, cả ba đều báo cáo được:

- Persona risk-seeking/averse **không** dịch chuyển ϕ_U , nhưng persona adversarial/cooperative **có** $\rightarrow$ bằng chứng mạnh hơn paper gốc cho chính luận điểm của paper gốc: kênh chiến lược lấn át kênh khuynh hướng cá nhân. Manipulation > measurement.
- **Cả hai** đều dịch chuyển $\rightarrow$ LLM khác người ở chỗ nó phản ứng với framing tính cách, và đây là giới hạn của LLM như một mô hình cho hành vi người — phải nói rõ.
- Persona risk **có** dịch chuyển còn adversarial **không** $\rightarrow$ kết quả ngược paper, và cực kỳ đáng báo cáo.

Một thiết kế mà mọi kết cục đều informative là một thiết kế tốt.

2.4 Manipulation check

Không có kiểm tra này thì mọi null của trực persona đều vô nghĩa: không phân biệt được "persona không ảnh hưởng hành vi" với "model không đọc persona". Hai check, chạy tách khỏi game:

1. **Free-text probe** — cùng prompt, thay phần CURRENT DECISION bằng *"Describe your development philosophy in one sentence."* $\rightarrow$ coder mù (hoặc LLM judge với rubric cố định, ghi rõ rubric) phân loại về đúng persona. Yêu cầu $\geq 80\%$ accuracy.
2. **Behavioural probe ngoài game** — một quyết định rủi ro đơn giản không liên quan đến race (bản LLM của Eckel–Grossman). Đây chính là bản LLM của Task 1 trong paper, và cho phép so trực tiếp: *khẩu vị rủi ro đo được* của LLM có dự báo ϕ_U không — song song hoàn hảo với H2 của paper.

2.5 Ba confound phải xử lý trước khi chạy

Confound	Xử lý
Persona gán với seat index	Counterbalance đầy đủ: mọi cell bất đối xứng có bản mirror ($S_{AC} \leftrightarrow S_{CA}$); đưa <code>seat</code> vào model như fixed effect

Persona = "thêm text" chứ không phải nội dung	Placebo R0 cùng độ dài, cùng cấu trúc câu, nội dung vô thưởng vô phạt
Persona của đối thủ bị rò rỉ sang seat kia	Kiểm tra build_prompt : persona chỉ vào prompt của chính seat đó (đúng theo prompt.py:71-79), nhưng phải có test khẳng định — nếu rò rỉ thì S_AC biến thành trò chơi thông tin hoàn hảo và không còn so được với người

§ 3. TRỰC 3 — Analysis

3.1 Bản đồ paper → LLM → file analyser đã có

Paper	Nội dung	Output analyser đã có	Còn thiếu
Fig 2A	ϕ_U theo treatment	unsafe_by_risk_model_player.csv	Không thiếu — nhưng dùng Bảng S3 làm chuẩn so sánh, không dùng caption Fig 2A (caption ghi ngược dấu, xem § 3.4)
Fig 2B	Unsafe ~ ΔS × own_prev × opp_prev	unsafe_by_race_state_turn.csv , opponent_response_turn.csv	Thiếu cell chéo 3 chiều trong một bảng
Fig 2C	ϕ_U winner vs loser, tương quan trong cặp	outcome_player.csv	Thiếu hệ số tương quan trong cặp theo treatment
Table 1	6 model logit lồng nhau	clustered_logit_coefficients.csv — chỉ 1 đặc tả	Thiếu 5 đặc tả còn lại
Fig S1	Phân bố số vòng	race_quality.csv	Cần histogram + kiểm tra mean ≈ 9

Fig S5	Phân bố chiến lược theo p_r^{max}	<code>strategy_summary_player.csv</code>	Đủ
--------	--	--	----

`LOGIT_FORMULA` hiện tại (`analyze_ai_race.py:27-30`) đúng bằng **model (6)** của paper. Cần thêm 5 đặc tả kia để tái tạo cấu trúc nested và cho thấy hệ số ổn định hay không — đây chính là chỗ paper người bộc lộ điểm yếu (ΔS chỉ significant ở model 6, không ở model 3).

3.2 Xử lý ΔS : bin, centering, và bẫy collinearity

ΔS là **lattice**, chỉ nhận bội của 0.5, và với horizon trung bình 9 thì thực tế nằm trong `[-4.5, +4.5]` , tập trung dày ở `{-1, -0.5, 0, +0.5, +1}` .

- Báo cáo **cả hai** dạng: ΔS liên tục (centered theo mean của **mẫu LLM**, ghi rõ giá trị centering — không dùng mean của mẫu người) và ΔS phân loại `{behind / tied / ahead}` (analyser đã tạo `race_state` ở `analyze_ai_race.py:1766-1770`).
- Thêm bin theo độ lớn: `{ $\leq -1$ ,  $-0.5$ ,  $0$ ,  $+0.5$ ,  $\geq +1$ }` . "Bị bỏ lại 0.5 bước" (lệch 1 vòng) khác về chất so với "bị bỏ lại 2 bước".
- **Bắt buộc report VIF** giữa `$\Delta S_{\{t-1\}}$` , `own_prev_unsafe` , và risk tích lũy. Từ § 0(4), $\Delta S = 0.5 \cdot \Delta n_U$ nên ΔS tương quan cơ học với lịch sử Unsafe. Paper không report chỉ số này; ta nên.

3.3 Đơn vị cụm và multiplicity

- **Cụm**: `randomization_block_id` (`source_run::model::rep`). Analyser đã ép mỗi block phải trải ≥ 2 treatment (`analyze_ai_race.py:2856-2864`) — đúng, giữ nguyên. Khi pool cross-persona phải mở rộng, xem § 4.3.
- **Primary vs secondary**: khai báo trước khi chạy. Đề xuất primary = ba hệ số `{opponent_prev, progress_gap, first_round}` trong đặc tả đầy đủ; Holm–Bonferroni trên 3. Mọi thứ khác là exploratory và phải ghi nhãn rõ trong mọi bảng.
- **Loại trừ**: giữ nguyên luật của repo — một `parse_failed` là **loại cả race**, vì Safe fallback lan vào state các vòng sau. Không nới lỏng `parse_action` để làm đẹp tí

lệ thành công.

3.4 Tiêu chí "replicate" — định nghĩa TRƯỚC khi nhìn kết quả

Đây là phần quyết định nghiên cứu có nói được gì hay không. Không có tiêu chí định trước thì mọi kết quả đều trở thành "một phần giống người".

#	Hiệu ứng người	Chuẩn người	Replicate nếu
E1	Opponent prev Unsafe → Unsafe ↑	$\beta = +0.607, p = 0.002$	$\beta > 0$ và $p < 0.05$ sau Holm
E2	Dẫn trước → Unsafe ↓	$\beta = -0.296, p = 0.048$	$\beta < 0$ và $p < 0.05$
E3	Vòng 1 Unsafe → sau Unsafe ↑	$\beta = +0.217, p < 0.1$	$\beta > 0$ và $p < 0.10$
E4	Own prev không dự báo	$\beta = -0.193, n.s.$	$ \beta < 0.3$ và TOST kết luận tương đương
E5	Treatment 0.6 vs 0.9 không khác	$d = -0.027$	$ d < 0.2$ qua TOST
E6	0.1 có ϕ_U cao hơn 0.6/0.9	$d \approx +0.33$	$d > 0.2$, cùng dấu
E7	ϕ_U tổng thể	0.584	Nằm trong $[0.40, 0.75]$
E8	AS gần như không tồn tại	AS không là Nash ở mọi treatment	tỉ lệ trajectory phân loại AS < 10%

E4 và E5 là null replication — phải dùng equivalence test (TOST), không phải " $p > 0.05$ nên giống nhau". Đây là chỗ đa số paper LLM-replication làm sai.

Cảnh báo về E6. Caption Fig 2A của paper viết "*Unsafe play is significantly higher in the 0.6 and 0.9 treatments than in the 0.1 treatment*", nhưng Bảng S3 cho mean $\phi_U = 0.640$ (ở 0.1) vs 0.558 / 0.564; Cohen's d cho "0.1 vs 0.6" là **+0.341** (dương $\Rightarrow$ nhóm 0.1 cao hơn); hệ số hồi quy của 0.6/0.9 đều âm so với 0.1; và mô hình tiến hoá cũng dự báo Unsafe cao nhất ở rủi ro thấp. Hướng đúng là **0.1 có Unsafe CAO hơn**. Dùng Bảng S2/S3 làm chuẩn, không dùng câu văn trong caption.

Deliverable cuối cùng của trục này là **một bảng 8 dòng**: replicate / không / không kết luận được, kèm hướng lệch. Rõ ràng hơn nhiều so với "LLM behaves similarly to humans".

3.5 Estimand chỉ LLM mới có (không có đối chứng người — báo cáo ở mục riêng)

- **Nhân quả thật của opponent action** (Arm B):
 $E[\text{unsafe} \mid \text{opp} = \text{AU}] - E[\text{unsafe} \mid \text{opp} = \text{AS}]$. Paper người không có con số này.
- **Tách vị trí vs ngân sách rủi ro** (Arm D): hệ số ΔS khi kiểm soát Δn_U .
- **Determinism / repeatability**: cùng seed, cùng prompt, chạy lại $\rightarrow$ tỉ lệ action trùng. Đây là **cận trên** của mọi hiệu ứng đo được và phải báo cáo trước mọi hệ số khác.
- **Tỉ số disposition/strategy**: effect size của persona chia cho effect size của opponent action. Đây là câu trả lời định lượng cho câu hỏi trung tâm của paper.
- **Sensitivity to seat/name**: artifact thuần, phải report để người sau biết.

3.6 Bảng mô tả tối thiểu phải sinh ra

Mọi bảng stratify theo `persona_condition × max_private_risk × model`:

1. ϕ_U theo treatment (turn-level và player-level) + t-test cặp + Cohen's d — bản LLM của Fig 2A / Bảng S2.
2. ϕ_U theo `opp_prev × own_prev` (4 ô) — bản LLM của Fig 2B.
3. ϕ_U theo `race_state × opp_prev` (6 ô) và theo bin ΔS 5 mức.
4. ϕ_U winner vs loser + tương quan trong cặp theo treatment — Fig 2C.
5. Ma trận chuyển trạng thái $P(\text{action}_t \mid \text{own}_{\{t-1\}}, \text{opp}_{\{t-1\}})$ — 4×2 , bản mô tả thuần của reciprocity, không cần model.
6. Phân bố nhãn chiến lược AS/AU/CS/CAS + tỉ lệ tie + mismatch rate — Fig S5. Giữ nguyên nguyên tắc của [strategy_analysis/](#): không ép tie thành nhãn duy nhất, và `BEHIND_UNSAFE_EXPLORATORY` không bao giờ gộp với 4 nhãn canonical trong bảng confirmatory.
7. Phân bố horizon + kiểm tra mean ≈ 9 — Fig S1.
8. Protocol health: parse-failure rate, retry count, refusal rate, độ dài response.

§ 4. Thay đổi code cần thiết (theo thứ tự bắt buộc)

4.1 Ghi persona vào output — chặn mọi run persona cho tới khi xong

File	Thay đổi
state.py	GameConfig: thêm persona_condition: str = "none", persona_sha256: str = "". TurnRecord: thêm persona_condition, seat_persona_role
recorder.py	race_row + player_rows: thêm persona_condition và player_N_persona_role / persona_role
run_experiment.py	Đọc personaCondition + personaRoles từ agents config; hash nội dung persona
analyze_ai_race.py:104	Thêm persona_condition vào CONTEXT
analyze_ai_race.py	Gate mới: nếu persona_condition thiếu ở bất kỳ race nào → refuse, trừ khi có flag mới --allow-missing-persona-condition. Dùng cùng khuôn với _resolve_prompt_versions
kaggle/experiments/baseline.py (dòng 361)	Manifest: thêm agents_name, agents_config_sha256, persona_condition, persona_sha256
results/README.md	Cập nhật mục "Expected schema" — CLAUDE.md yêu cầu, nếu không thì completed run sẽ fail audit

Gate consistency bắt buộc: `persona_condition == "none"` $\iff$ cả hai persona rỗng. Vi phạm → raise. Đây là thứ ngăn được lỗi tệ nhất có thể xảy ra: chạy persona rồi báo cáo như baseline.

4.2 Backend chiến lược script (cho Arm B)

`ai_race/models/scripted.py`: một callable tương thích `send_batch` trả ACTION: SAFE|UNSAFE theo AS / AU / CS / CAS / BEHIND / RANDOM(seed).

Vấn đề kiến trúc: `send_batch(prompts, seeds)` chỉ nhận prompt string, không nhận state. Hai lựa chọn:

- (a) parse state từ prompt — fragile, không nên;
- (b) cho `run_games_batched` route theo seat; seat scripted đọc `game` object trực tiếp.

Chọn (b). Và ghi `model = "scripted:AU"` để analyser thấy rõ đây không phải LLM và không gộp nhầm vào thống kê model.

4.3 CRN block khi pool cross-persona

`randomization_block_id` hiện là `source_run::model::rep`. Khi pool nhiều persona run directory, cùng `rep` chia sẻ horizon nhưng khác `source_run` → block bị tách sai.

Sửa: khi mọi run có cùng `experiment.seed` (đọc được từ manifest), block trở thành `model::rep`; nếu seed khác nhau thì giữ nguyên và **cảnh báo rõ rằng CRN không trải qua persona**. Điều kiện tiên quyết: **mọi experiment config dùng chung "seed": 260726**.

4.4 Sáu đặc tả logit lồng nhau

Đổi `_fit_clustered_logit` để chạy một list công thức thay vì một công thức duy nhất, xuất `clustered_logit_coefficients.csv` có thêm cột `specification` $\in \{1..6\}$, khớp Table 1 của paper.

§ 5. Trình tự thực thi

Kaggle push/run/download là **checkpointed**: chạy một lệnh, hiện output, dừng, chờ người dùng trước lệnh kế tiếp (theo `CLAUDE.md` và [kaggle/benchmarks/README.md](https://www.kaggle.com/benchmarks/README.md)).

#	Bước	Gate để đi tiếp
0	Viết preregistration: primary estimand, tiêu chí § 3.4, luật loại trừ, N, ngưỡng degenerate	Đóng băng trước khi nhìn output AI Race đầu tiên
1	Code § 4.1 + § 4.4 + tests; <code>pytest</code> xanh	Test persona-consistency và length-balance pass
2	Smoke local <code>--mock random</code> , 2 rep; kiểm tra cột persona xuất hiện đúng	Analyser chạy sạch trên output mock
3	Kaggle pilot : 1 model open-weight, điều kiện <code>none</code> + <code>S_AA</code> , 10 rep, temp 0.7	7 validation gate trong PROJECT.md đều pass; tỉ lệ $\Delta S \equiv 0 < 40\%$; parse-failure $< 5\%$
4	Tính lại N từ ICC quan sát được ở pilot	Chốt số rep cuối cùng

5	Freeze prompt / config / agents / analysis plan; lật <code>runPhase</code> → <code>confirmatory</code>	Không sửa gì sau bước này
6	Chạy full lưới: 8 điều kiện × 3 treatment × N rep, 1–2 model open-weight	Manifest <code>status = completed</code> cho mọi run
7	Code § 4.2, chạy Arm B (đối thủ ngoại sinh)	
8	Chạy analyser một lần , không đổi định nghĩa outcome sau khi thấy kết quả	
9	Arm D (non-canonical, <code>--allow-noncanonical-mechanism</code>), báo cáo tách riêng	
10	Điền Results vào <code>paper/</code> và figure vào <code>slides/</code>	Chỉ sau khi bước 8 xong

Về chi phí: full lưới $\approx 2.700 \text{ call} \times 8 \text{ điều kiện} \approx 21.6\text{k call} / \text{model}$. Với open-weight trên GPU Kaggle là khả thi. Với frontier API, chạy lưới rút gọn (`none` , `S_AA` , `S_AC` , `R+`) và nói rõ trong Methods rằng lưới bị cắt vì chi phí.

§ 6. Danh sách freeze (không được đổi sau bước 5)

- `ai_race/prompts/ai_race_en.txt` — hash `6180d4f699813a602a53cf4290b972aa4df4bf02ff1c646a85ab09d80d7729ff`
- Nội dung mọi persona (+ `persona_sha256`)
- `seed: 260726` cho **mọi** experiment config (điều kiện để CRN trải qua persona)
- Temperature, max_tokens, decoding params
- Luật loại trừ (parse-failure loại cả race)
- Tiêu chí replicate § 3.4 và bộ primary estimand § 3.3
- Số rep

§ 7. Rủi ro đã biết

Rủi ro	Xác suất	Giảm thiểu
--------	----------	------------

Symmetry collapse, $\Delta S \equiv 0$	Cao	§ 1.2 ba lớp L1/L2/L3
Model quá đơn điệu (toàn AU hoặc toàn AS) → logit không fit	Trung bình	Report ϕ_U mô tả kể cả khi logit fail; Arm B cứu variance
Persona bị pool ngầm với baseline	Cao nếu không vá § 4.1	Gate consistency, bắt buộc trước run persona
Persona không được đọc → null giả	Trung bình	Manipulation check § 2.4
Persona confound với seat	Cao nếu không counterbalance	Mirror cell $S_{AC} \leftrightarrow S_{CA}$
Diễn giải ΔS sai vì collinearity	Chắc chắn xảy ra nếu không xử lý	§ 0(4), VIF ở § 3.2, Arm D
Chi phí frontier API vượt ngân sách	Trung bình	Lưới rút gọn, khai báo rõ