

AI Race: LLM có hành xử như người không?

Báo cáo tiến độ — PILOT, chưa confirmatory

4 lần chạy pilot: baseline (Qwen/Gemma), frontier (Gemini), openai (GPT-nano), N-player (Qwen)


AI Race Lab

August 1, 2026

1. Nhắc nhanh khung thí nghiệm
2. Phạm vi 4 lần chạy pilot
3. Baseline 2-player: Qwen2.5-14B vs Gemma-3-12B
4. Frontier: họ Gemini
5. OpenAI: GPT-5-nano / GPT-5.4-nano
6. N-player (N=3): Qwen2.5-14B
7. Tổng hợp xuyên mô hình
8. Giới hạn & việc cần làm tiếp

Nhắc nhanh khung thí nghiệm

Một vòng chơi, 5 bước, rủi ro riêng cho người thắng



$$q_i = p_{\max} \cdot \frac{n_i^U}{T}$$

Rủi ro chỉ áp dụng cho người thắng / hòa thắng, tại thời điểm dừng.

4 câu hỏi gốc

1. Mức rủi ro ($p_{\max}$) có đổi hành vi không?
2. Hành động U_{t-1} của đối thủ có dự báo U_t ?
3. Bị dẫn trước có dự báo U_t ?
4. Vòng 1 có mang theo về sau?

Nguồn

Fernández Domingos & Han (2026), arXiv:2607.26034 — 4 câu hỏi này là khung phân tích xuyên suốt 4 pilot tiếp theo.

Phạm vi 4 lần chạy pilot

4 pilot, 4 họ model, quy mô rất khác nhau

BASELINE

Qwen2.5-14B
Gemma-3-12B

60 race

558 quyết định

2-player, 10 rep

FRONTIER

3× Gemini 3
+ 5 cell persona

177 race

3.168 quyết định

proxy Kaggle

OPENAI

gpt-5-nano
gpt-5.4-nano

2.640 race

49.104 quyết định

+ma trận rủi ro 6×6

N-PLAYER

Qwen2.5-14B
(N=3)

60 race

1.404 quyết định (từ
vòng 2)

+persona Eckel-Grossman

Tất cả đều là run_phase = pilot

Không có lần chạy nào đạt **confirmatory** theo PROJECT.md. Mọi con số sau đây đọc như tín hiệu định hướng.

Kiểm tra	baseline	frontier	openai	nplayer
Parse failure	✓ 0/1.116	✓ 0/3.168	✓ 0/49.104	✓ 0%
Đẳng thức ΔS (residual)	✓ 0,0	✓ 0,0	✓ 0,0	✓ khớp
Cân bằng ghế	✓ chênh 0,03	—	✓ chênh 0,025	—
<code>check_symmetry.py</code>	✗ 65% (Gemma)	—	✓ 20%	—
CRN block	✓ 10	✓ 30	✓ 20	✓ 20

Đọc bảng này thế nào

Cơ chế game (state, payoff, seed) **đúng** ở cả 4 pilot. Cổng duy nhất FAIL là symmetry ở baseline — nguyên nhân hoàn toàn từ Gemma hòa 100% (slide sau), không phải lỗi đường ống.

Baseline 2-player: Qwen2.5-14B vs
Gemma-3-12B

Triệu chứng

558/558 lượt gọi trả đúng cùng một chuỗi: ``ACTION: SAFE'`. $\phi_U = 0,000$ ở cả ba mức rủi ro, với 186 seed phân biệt.

Đường ống đã loại trừ

- ✓ `parse_failed = 0`, `retry = 0`
- ✓ 186 seed áp dụng đúng
- ✓ prompt render đúng, hoán vị ghế đúng
- ✓ `temperature 0,7 > 0`, `do_sample=True`
- ✓ model nạp đúng, khớp Qwen 30 race/558 lượt




Hai giả thuyết chưa phân biệt được

(A) Gemma hiểu trò chơi, kết luận Safe tối ưu.


(B) Gemma từ chối token **UNSAFE** do safety-tuning.

Phép thử quyết định: đổi nhãn thành **OPTION_A/B**.



Diễn giải

Safe tuyệt đối ở cả 30 race trong vòng 1-4 (36% mẫu panel, tắt định hoàn toàn), bật Unsafe đúng từ vòng 5 — vòng đầu tiên race **có thể** kết thúc. Qwen đang đọc luật dừng và chơi endgame có lý.




Chênh lệch bị-dẫn trừ dẫn-trước

+0,38 / +0,81 / +0,50 — nhất quán và lớn ở cả ba treatment. Đúng phát hiện trung tâm của Fernández Domingos & Han (2026).

own \ opp _{t-1}	Safe	Unsafe
Safe	0,404 n=146	0,892 n=65
Unsafe	0,154 n=65	0,048 n=42

Độc ma trận


Đối thủ vừa Unsafe, mình vừa Safe $\Rightarrow$ 89,2% mình chuyển Unsafe. Nhưng mình vừa Unsafe xong $\Rightarrow$ gần như chắc chắn lui về Safe (4,8%). Chia lượt, không phải momentum.



Cẩn thận


Chỉ 10 CRN cluster $\Rightarrow$ SE lạc quan. Đọc dấu/độ lớn như tín hiệu, không phải ước lượng chắc chắn. own_{t-1} **trái ngược** paper (paper: "không dự báo").

Frontier: họ Gemini




Ngược hướng với null quan trọng nhất của paper

Người: 0,6 vs 0,9 không khác nhau (H1.2 bị bác bỏ). Cả ba Gemini: **có ý nghĩa thống kê** ($d = 1,03-1,87$, $p < 0,01$) — và bão hòa gần 1,0 ở risk=0,1.



Nghịch lý

S_AC (ghế "adversarial" nhưng đối thủ cooperative) lại **thấp hơn** cả S_CA. Chỉ mô tả thô — mỗi persona chạy ở một protocol signature riêng, không tách được khỏi nhiều batch.



Khớp hướng người, nhưng mạnh hơn nhiều


opponent(t-1): người +0,607 → Gemini **+1,486** (gấp ~2,4 lần). **Unsafe vòng 1**: người +0,217 ($p < 0,1$) → Gemini +1,674 ($p = 0,001$). Nhưng **treatment** có ý nghĩa mạnh — ngược paper.

E1 opponent(t-1) replicated (mạnh hơn)	E2 ΔS not replicated	E3 vòng 1 replicated	E4 own(t-1) ≈ 0 not replicated
E5 0,6 vs 0,9 ≈ 0 not replicated	E6 0,1 vs 0,6 replicated (d=3,08)	E7 ϕ_U tổng replicated (0,624)	E8 share AS not replicated

Lưu ý về cách chấm

"Replicated" chỉ xét **dấu** và ngưỡng ý nghĩa, không xét độ lớn có bằng người hay không. E1/E3/E6 "replicated" nhưng hệ số lớn hơn người 2-9 lần.


OpenAI: GPT-5-nano / GPT-5.4-nano



Điểm trung thực ở risk=0,6

gpt-5.4-nano, mẫu $t \geq 2$: $0,1 \leftrightarrow 0,6$ ($d=0,662$, $p=0,043$) và $0,6 \leftrightarrow 0,9$ ($d=-0,689$, $p=0,036$) **có ý nghĩa**; $0,1 \leftrightarrow 0,9$ gần bằng nhau ($p=0,86$). Không bảo hòa gần 1,0 như Gemini.

Persona: thứ hạng nhất quán trên 2 model độc lập



Thứ hạng hợp lý nhất trong cả hai pilot

R- thấp nhất, R+ cao nhất, $S_{CC} \approx 0$. Nhưng **gpt-5-nano sụp về Safe với BẤT KỲ persona nào**, kể cả R0 trung lập (0,14→0,015) — hiệu ứng "có persona hay không", không phải hướng persona.

Ma trận rủi ro 6×6 (gpt-5.4-nano): mình chỉ phối, đối thủ bù trừ

own\opp	1	2	3	4	5	6
1	,002	,004	,002	,000	,008	,006
2	,000	,000	,003	,006	,003	,002
3	,479	,463	,385	,300	,252	,250
4	,628	,581	,506	,446	,390	,345
5	,833	,869	,834	,796	,729	,702
6	,982	,982	,983	,991	,985	,988


Hàng: mức của MÌNH

≈ 0 (mức 1-2) $\rightarrow$ gần 1,0 (mức 6) — **dose-response** sạch hơn người (paper: không tìm thấy quan hệ nào).

Cột: mức của ĐỐI THỦ

Trong mỗi hàng, ϕ_U **giảm dần** khi đối thủ "ưa rủi ro" hơn — chiều bù trừ, khớp dấu âm của `opponent_prev` ở slide sau.

Hồi quy panel GPT-nano: đảo dấu hoàn toàn — phát hiện nổi bật nhất



Người: opp(t-1) +0,607, ΔS -0,296 — ở đây cả hai đảo dấu

opponent_prev: **-1,016** (phòng thủ, không leo thang). ΔS : **+0,490** (dẫn trước → củng cố, không bảo toàn). **Cảnh báo:** statsmodels báo converged: False cả 6 đặc tả (quasi-separation, 88 dummy protocol) — đọc như tín hiệu thô.

8 hiệu ứng người-LLM (E1-E8): chỉ 2/8, và 2 cái đảo dấu


E1 opponent(t-1) đảo dấu: -1,016	E2 ΔS đảo dấu: +0,490	E3 vòng 1 replicated	E4 own(t-1) ≈ 0 not replicated
E5 0,6 vs 0,9 ≈ 0 replicated	E6 0,1 vs 0,6 not replicated (≈ 0)	E7 ϕ_U tổng not replicated (0,353)	E8 share AS not repl. (0,562)

Khác Gemini không chỉ ở số lượng mà ở kiểu

Gemini "not replicated" vẫn đúng dấu. GPT-nano ở E1/E2 **đảo dấu hoàn toàn**. Bảng gộp 44 cell rất không đồng nhất — đọc như trung bình thô.


N-player (N=3): Qwen2.5-14B

ϕ_U giảm theo rủi ro (69%→57%→47%), $p < 0,001$



So với lý thuyết quần thể


Kể cả sau khi **quét β** tìm điểm khớp tốt nhất (chặt hơn cách cố định 2 điểm của frontier), lý thuyết vẫn dự báo **dốc giảm mạnh hơn** thực tế ở risk 0,6/0,9.



Độc cẩn thận

Sơ đồ minh họa định tính (không phải số đo chính xác từng mức). Chỉ 2 race/ô — không đưa vào hồi quy được, cần xác nhận lại bằng confirmatory run.


Tổng hợp xuyên mô hình



Câu trả lời sơ bộ: không

Bốn pilot tổng hợp tiếp theo cho thấy **hình dạng** và thậm chí **dấu** của hiệu ứng thay đổi theo từng model.



$\phi_U(risk)$ không cùng hình dạng giữa các nguồn



Không có "hành vi LLM" phổ quát

5 đường, 5 hình dạng khác nhau: phẳng, dốc đơn điệu, chữ U, thấp-ổn định, giảm nhẹ. Chọn model là chọn cả một **hình dạng hành vi**, không chỉ một con số trung bình.

Dấu hệ số opponent_prev và ΔS đảo chiều theo model



Ảnh quan trọng nhất của đợt này

Xanh = cùng dấu người. **Đỏ** = đảo dấu. Chỉ GPT-nano đảo cả hai hiệu ứng trung tâm của paper gốc cùng lúc — nhưng hồi quy đó converged=False, nên đọc như tín hiệu thô, chưa kết luận.

Tỷ lệ tái tạo 8 hiệu ứng người: không model nào đầy đủ, không theo cùng một cách



Khác nhau cả ở *loại* không-khớp

Gemini: 4 không-khớp đều là đúng dấu nhưng quá mạnh. GPT-nano: 6 không-khớp, trong đó **2 cái đảo dấu hoàn toàn**. Không thể tổng quát hóa "LLM hành xử như người" hay ngay cả "LLM hành xử giống nhau".

Giới hạn & việc cần làm tiếp

Thống kê

- Tất cả `run_phase = pilot`, chưa `confirmatory`.
- OpenAI: hồi quy **không hội tụ** (quasi-separation, 88 dummy protocol).
- Baseline/nplayer: chỉ 10–20 CRN cluster — SE lạc quan.
- N-player persona: 2 race/ô, không đủ cho hồi quy.

Đo lường

- Persona **confound với protocol/batch** ở cả frontier và openai — 2 nguyên nhân cấu trúc khác nhau.
- `first_round_unsafe` hằng số $\Rightarrow$ nhiều đặc tả hồi quy **singular**.
- Gemma: 2 giả thuyết (A)/(B) chưa phân biệt được.

Nguyên tắc báo cáo

Chỉ nói **tín hiệu pilot**; không dùng deck này làm bằng chứng cho bất kỳ RQ nào trong PROJECT.md.

1. Phép thử đổi nhãn `OPTION_A/B` cho Gemma — phân biệt giả thuyết (A) hiểu luật vs (B) từ chối từ.
2. Tạo biến thiên vòng 1 (persona `risk_seeking/adv_adv`) để `first_round_unsafe` hết là hằng số.
3. Chạy persona cùng session / qua **kaggle_benchmarks** để gỡ confound protocol.
4. **Mixed-effects logit** (TA.4) và **EGTtools** (TD.2) để mở khóa các mục đang thiếu.
5. Khóa protocol và đặt `RUN_PHASE_OVERRIDE=confirmatory` chỉ sau khi 4 bước trên xong.

Thứ tự

(1) và (2) chặn đường trước tiên — chạy thêm repetition bây giờ chỉ nhân bản hai vấn đề này lên, không thêm thông tin.

Kết

Bốn model, bốn hành vi khác nhau — kể cả **đảo dấu** hiệu ứng trung tâm của paper người.

Chưa đủ confirmatory để kết luận — nhưng đủ để không giả định LLM hành xử như người, hay giống nhau.

Cảm ơn — rất mong nhận được góp ý.

Backup 1 — Hệ số hồi quy đầy đủ, cả 4 nguồn

Biến	Người	Gemini (spec 6)	GPT-nano (spec 6)	Qwen 2p (spec 2)	Qwen 3p (spec 3)
opponent/others(t-1)=U	+0,607 (p=0,002)	+1,486 (p<0,001)	-1,016 (p<0,001)	+2,339 (p<0,001)	+1,472 (p<0,001)
own(t-1)=U	-0,193 (n.s.)	-0,595 (n.s.)	+0,170 (n.s.)	-2,234 (p<0,001)	+1,101 (p<0,001)
ΔS (progress gap)	-0,296 (p=0,048)	-0,224 (n.s.)	+0,490 (p<0,001)	-0,717 (p=0,013)	+0,032 (n.s.)
Unsafe vòng 1	+0,217 (p<0,10)	+1,674 (p=0,001)	+0,635 (p<0,001)	không ước lượng được	hằng số
Pseudo R ²	0,006–0,040	0,450	0,347	0,194	—
Hội tụ?	có	có	không	có (spec 1–2)	có

Nguồn: `analysis/baseline.md` §4.4; `analysis/frontier/report.md` §4; `analysis/openai/report.md` §5;
`analysis/nplayer/derived/clustered_logit_coefficients.csv` spec 3.

4 file nguồn (không tính lại từ CSV thô)

```
analysis/baseline.md · analysis/frontier/report.md · analysis/openai/report.md · analysis/nplayer/report.md
```

Lệnh tái tạo (ví dụ openai)

```
.venv-kaggle/bin/python3 results/scripts/analyze_ai_race.py \  
  --input results/frontier/openai --output analysis/openai/derived \  
  --fit-logit --fit-logit-robustness \  
  --allow-mixed-protocols --allow-nonfinal-runs \  
  --allow-nonconfirmatory-runs --allow-missing-persona-condition
```

Freeze before you look

Mọi con số trên đây gắn với `run_manifest.json` và `prompt_sha256` đã khóa. Đổi `prompt/config = promptVersion` mới, không pool chung.

2026 — ARXIV:2607.26034

Falling Behind Drives Unsafe Development in an Idealised AI Race Experiment

E. Fernández Domingos & T. A. Han

<https://arxiv.org/abs/2607.26034>

TÀI LIỆU DỰ ÁN

Engine, prompt, config, test và kế hoạch phân tích được lưu trong repo này (CLAUDE.md, PROJECT.md, analysis/).